

Derin Pekiştirmeli Öğrenme ile Otonom Enerji Tasarrufu: Akıllı Termostat Optimizasyonu

Autonomous Energy Savings with Deep Reinforcement Learning: Smart Thermostat Optimization

Kadir ÇELİK

Bursa Teknik Üniversitesi
Lisansüstü Eğitim Enstitüsü
Akıllı Sistemler Mühendisliği
Bursa, Türkiye
25434998010@ogr.btu.edu.tr
0009-0001-4340-3948

Öz

Mevcut çalışmada, ofis iklimlendirme sistemlerinde enerji tasarrufu ve insan konforu arasındaki dengeyi optimize etmek üzere Derin Pekiştirmeli Öğrenme tabanlı otonom bir akıllı termostat ajanı geliştirilmesini sunmaktadır. Geleneksel kural tabanlı ve tablo tabanlı Q-öğrenme yöntemlerinin sınırlamalarını aşmak amacıyla, ortam dinamiklerini sürekli bir durum uzayında işleyen yapay sinir ağları kullanılmıştır. Proje kapsamında gerçekçi bir termodinamik fizik motoru tasarlanmış, ajanın öğrenme sürecini yönlendirmek için karesel ceza işlevine dayalı özel bir ödül mekanizması geliştirilmiştir. Simülasyon sonuçlarına göre, eğitilen ajan beş yüz bölümlük deneyim sonucunda ofis içerisindeki sıcaklığı belirlenen hedef aralıkta yüzde doksan beşin üzerinde bir başarıyla tutmayı öğrenmiştir. Geliştirilen otonom sistem, anlık hava koşullarını ve iç ısı yüklerini hesaba katarak proaktif kararlar alabilmekte, böylece enerji israfını en aza indirirken konfor koşullarını maksimum seviyede korumaktadır.

Anahtar sözcükler: Derin pekiştirmeli öğrenme, Akıllı termostat, Enerji verimliliği, Termodinamik modelleme, Yapay zeka

Abstract

This paper presents the development of an autonomous smart thermostat agent based on Deep Reinforcement Learning to optimize the balance between energy savings and human comfort in office HVAC systems. To overcome the limitations of traditional rule-based and tabular methods, artificial neural networks were used to process environment dynamics in a continuous state space. Within the scope of the project, a realistic thermodynamic physics engine was

designed, and a custom reward mechanism based on a quadratic penalty function was developed to guide the learning process of the agent. According to the simulation results, the trained agent learned to keep the temperature inside the office within the target range with over ninety-five percent success after five hundred episodes of experience. The developed autonomous system can make proactive decisions by accounting for instantaneous weather conditions and internal heat loads.

Keywords: Deep reinforcement learning, Smart thermostat, Energy efficiency, Thermodynamic modeling, Artificial intelligence

1. Giriş

Ofis iklimlendirme (HVAC) sistemleri, bina enerji tüketiminin büyük bir bölümünü oluşturmaktadır. Geleneksel termostatlara çoğunlukla yalnızca mevcut iç sıcaklığa dayalı basit kural tabanlı (Aç/Kapat) yöntemlerle çalışır ve dış ortam dinamikleri ile mesai saatlerindeki değişken iç ısı yüklerini öngöremez. Bu durum, enerji israfına ve optimum konfor hedeflerinden sapmalara neden olmaktadır. Bu çalışmada, ofis içerisindeki sıcaklığı ideal seviyede (25°C) tutarken enerji kullanımını minimize eden Derin Pekiştirmeli Öğrenme (DQN) tabanlı bir otonom ajan geliştirilmiştir. Geleneksel Q-Learning algoritmalarının ayrık durum uzayı sınırlamaları, PyTorch tabanlı derin sinir ağları ile aşılacak sürekli (continuous) değişkenlerin işlenebildiği bir yapı sunulmuştur.

2.Literatür

Akıllı binalarda enerji optimizasyonu ve iklimlendirme (HVAC) kontrolü üzerine yapılan önceki çalışmalar, genellikle oransal-integral-türevsel (PID) veya bulanık mantık (fuzzy logic) gibi kural tabanlı sistemlere dayanmaktadır. Ancak bu sistemler, dinamik çevre koşullarına (dış hava değişimi, ofis içi insan yoğunluğu) uyum sağlamada yetersiz kalmaktadır. Son yıllarda yapay zeka ve pekiştirmeli öğrenmenin (RL) gelişimiyle birlikte, Sutton ve Barto'nun [1] ortaya koyduğu Markov Karar Süreçleri altyapısı, HVAC optimizasyonunda yeni bir akademik standart haline gelmiştir. Geleneksel tablo tabanlı Q-Öğrenme algoritmaları, ayrık durum uzaylarında başarılı sonuçlar verse de, ofis iklimlendirmesi gibi sürekli (continuous) değişkenlerin olduğu dinamik ortamlarda boyutluluk laneti (curse of dimensionality) problemiyle karşılaşmaktadır. Mnih ve ark. [2] tarafından literatüre kazandırılan Derin Q-Ağları (DQN), bu problemi derin sinir ağları kullanarak çözmüş ve otonom sistemler için bir dönüm noktası olmuştur. İklimlendirme özelinde Wei ve ark. [3] yaptıkları çalışmada, derin pekiştirmeli öğrenme kullanarak bina HVAC sistemlerinde enerji maliyetlerini azaltmayı başarmışlardır. Benzer şekilde, Gao ve ark. [4] termal konforu sağlamak için yapay zeka tabanlı yaklaşımlar önermiş, ancak sürekli veri setlerinde Q-tablolarının yetersizliğini ve hesaplama maliyetlerini vurgulamışlardır. Yu ve ark. [5] ise akıllı termostatlar için derin öğrenme modelleri kurarak enerji tasarrufunda önemli iyileştirmeler raporlamıştır. Bu çalışma, literatürdeki bu boşlukları doldurmak amacıyla, gerçekçi termodinamik fizik dinamiklerini ve hedeften sapmaları üstel olarak cezalandıran "Karesel Ceza" fonksiyonunu DQN mimarisiyle birleştirerek literatüre özgün bir katkı sağlamayı hedeflemektedir.

3.Materyal ve Yöntem

Geliştirilen sistem, bir termodinamik fizik simülasyonu ve bu ortamda kararlar alarak öğrenen bir sinir ağı mimarisinden oluşmaktadır.

3.1 Termodinamik Çevre Dinamikleri

Gerçek dünya fizik kurallarına dayanan ortamda, her $\Delta t = 60s$ (1 dakika) için ofis içindeki net sıcaklık değişimi ΔT_{int} , enerji korunumu yasalarına göre modellenmiştir. Sistemin ısı dinamiği Denklem 1'de gösterilmiştir [41, 42]:

$$\Delta T_{int} = \frac{[\dot{Q}_{leak} + \dot{Q}_{internal} + \dot{Q}_{hvac}] \cdot \Delta t}{V \cdot \rho_{hava} \cdot c_{p,hava}} \quad (1)$$

Burada Q_{leak} iletimle olan ısı kaybını, $Q_{internal}$ kişi başı 125 W vücut ısını temel alan iç termal yükü ve Q_{hvac} ajanın motor gücü eylemini temsil etmektedir.

3.2 Markov Karar Süreci ve Karesel Ceza

Problem, bir Markov Karar Süreci (MDP) olarak modellenmiştir. Ajanın durum uzayı, günün dakikası, dış hava sıcaklığı, iç ortam sıcaklığı, bina yalıtım katsayısı ve odadaki insan sayısı olmak üzere 5 sürekli değişkenden oluşmaktadır. Ajan, bu durumlara karşılık 0W, 2500W veya 5000W klima motor gücü kullanma eylemlerinden birini seçer. Hedef sıcaklıktan (25°C) sapmayı optimize etmek için, klasik doğrusal ödüller yerine Karesel Ceza (Quadratic Penalty) fonksiyonu uygulanmıştır.

$$R(s_t, a_t) = -\omega_1 (T_{int} - T_{ref})^2 - \omega_2 \dot{P}(a_t) + \dot{C} \quad (2)$$

Denklem 2 sayesinde ajan, ekstrem hava koşullarında agresif performansı seçmeyi, hedefe yaklaştığında ise rölanti moda geçerek enerjiyi kısmayı matematiksel olarak öğrenir.

3.3 Deep Q-Network (DQN) Algoritması

Ajan, durum-eylem değerlerini tahmin etmek için derin bir sinir ağı kullanmaktadır. Öğrenme sürecinde, Bellman Optimalite Denklemi temel alınarak hesaplanan Temporal Difference (TD) hatası (Denklem 3) minimize edilmektedir [41, 42]:

$$L(\theta) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (3)$$


Model hiperparametreleri, stabil bir öğrenme sağlamak üzere Çizelge-1'de [28] sunulduğu gibi yapılandırılmıştır.

Çizelge-1: DQN Eğitim Hiperparametreleri

Parametre	Değer	Açıklama
Toplam Bölüm (Episodes)	500	Ajanın ofisi yönettiği toplam gün sayısı.
Batch Size	64	Deneyim hafızasından çekilen veri.
Target Update Freq	10	Hedef ağı güncellenme periyodu.
Başlangıç Keşif Oranı (epsilon)	1,00	Eğitimin başındaki rastgelelik oranı.
Bitiş Keşif Oranı	0,08	Eğitim sonu minimum keşif oranı.

4. Bulgular ve Tartışma

Sistem, belirlenen hiperparametrelerle 500 simülasyon günü boyunca eğitilmiştir. Eğitim sürecinde alınan toplam ödüllerin değişimi izlenerek modelin hedef davranışa yakınsadığı doğrulanmıştır. Şekil-1'de [24] ajanın eğitim bölümüne göre gösterdiği gelişim grafiği sunulmuştur.



Şekil-1: DQN Modeli Öğrenme Eğrisi

Eğitilmiş model ile yapılan 1 günlük test simülasyonunda ajan, ofis içi sıcaklığını belirlenen konfor aralığında tutmada büyük bir başarı göstermiştir. Yapılan ölçümlerde konfor oranı (hedef sıcaklık bandında kalma) %95'in üzerinde olarak kaydedilmiş ve ajanın test günü toplam ödül skoru 6768,66 [54] değerine ulaşmıştır.

5. Sonuç ve Gelecek Çalışmalar

Bu çalışmada, ofis iklimlendirme sistemleri için PyTorch altyapısında DRL tabanlı bir otonom ajan geliştirilmiş ve test edilmiştir. Karesel ceza mantığına dayanan ödül fonksiyonu ve termodinamik çevre simülasyonu sayesinde ajan, insan müdahalesine gerek kalmadan %95'in üzerinde bir konfor ve yüksek enerji optimizasyonu (6768.66 toplam test ödüllü) sağlamıştır. İleriki çalışmalarda, sürekli durum değişkenlerinin sinir ağına iletilmeden önce 0 ile 1 aralığına ölçeklendiği durum normalizasyonu işlemlerinin entegre edilmesi ve aşırı kestirim (overestimation) problemlerini önlemek amacıyla Double DQN (DDQN) mimarisinin uygulanması planlanmaktadır.

Kaynakça [Öz Başlık]

- [1] Sutton, R. S., Barto, A. G. *Reinforcement Learning: An Introduction*, MIT Press, 2018, pp. 249-253.
- [2] Mnih, V., Kavukcuoglu, K., Silver, D., ve ark. *Human-level control through deep reinforcement learning*, Nature, 2015, pp. 529-533.
- [3] Wei, T., Wang, Y., Zhu, Q. *Deep reinforcement learning for building HVAC control*, IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2017, pp. 2225-2238.
- [4] Gao, G., Li, J., Wen, Y. *Energy-efficient thermal comfort control in smart buildings via deep reinforcement learning*, arXiv preprint, 2019, pp. 1-10.
- [5] Yu, L., Qin, S., Zhang, M., Shen, C. *A review of deep reinforcement learning for smart building energy management*, IEEE Internet of Things Journal, 2020, pp. 120-135.